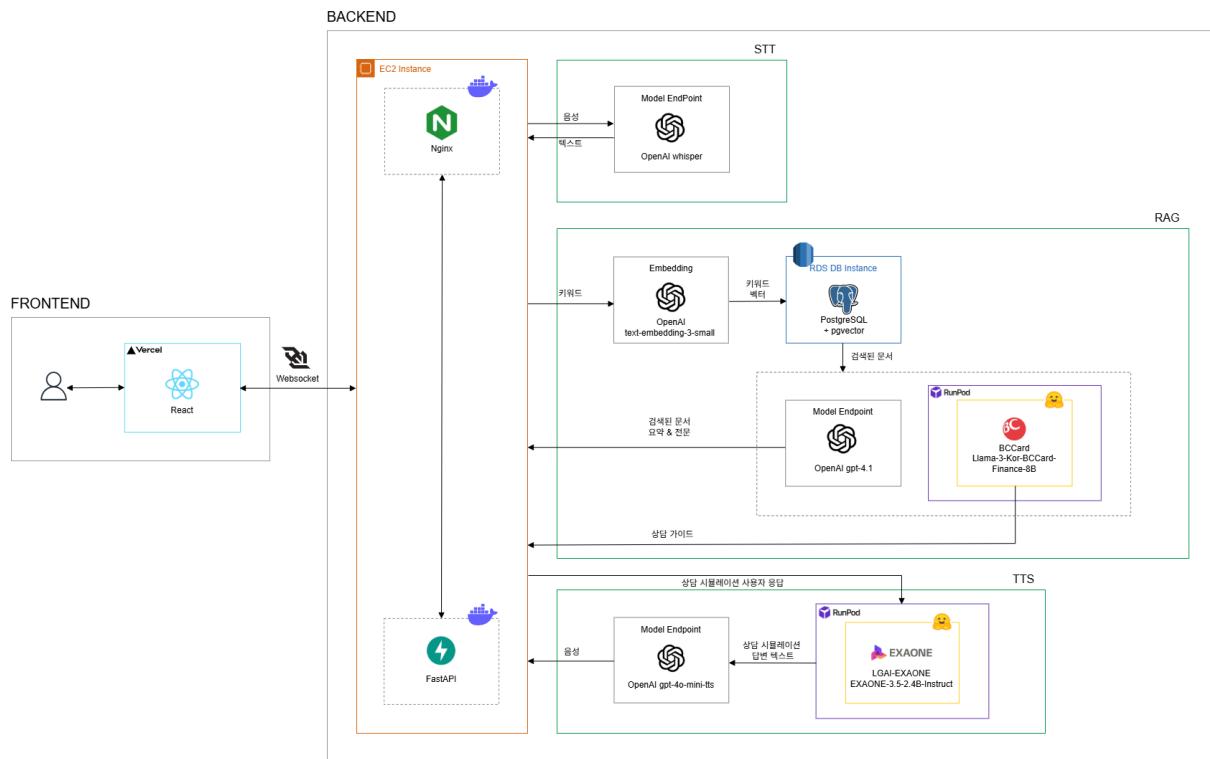




시스템 아키텍처



1. Frontend

- **React (Vercel을 통해 배포)**

사용자로부터 음성 입력을 받고, 백엔드와 WebSocket을 통해 실시간으로 통신

2. Backend

- **Nginx**

프록시 서버로서 외부의 요청을 받아 내부 도커 컨테이너로 전달

- **FastAPI**

시스템의 메인 로직을 담당

프론트엔드와의 WebSocket 연결을 유지

STT, RAG, TTS 기능 오케스트레이션

3. 핵심 서비스 모듈

- **STT**
 1. FastAPI로부터 전달받은 음성 데이터를 OpenAI Whisper 모델 엔드포인트로 전송
 2. 음성 데이터가 텍스트로 변환되어 백엔드 → 프론트엔드로 반환
- **RAG**
 1. Embedding: `OpenAI text-embedding-3-small` 모델을 사용하여 키워드를 벡터로 변환
 2. Vector DB: PostgreSQL(+pgvector) 데이터베이스에서 유사한 문서 검색
 3. LLM
 - `OpenAI gpt-4.1`: 검색된 문서의 요약 및 전문 생성
 - `Llama-3-Kor-BCCard-Finance-8B`: 상담 가이드 생성
 4. 생성한 데이터를 백엔드 → 프론트엔드로 반환
- **TTS**
 1. 상담 답변 생성: `EXAONE-3.5-2.4B-Instruct` 모델을 통해 상담원의 응답에 적절한 답변 텍스트 생성
 2. 생성된 텍스트를 `OpenAI gpt-4o-mini-tts`로 전달하여 음성 파일로 변환
 3. 생성된 음성을 백엔드 → 프론트엔드로 반환